

Projetando a UX em Produtos com LLMs (IA Generativa)

Introdução

O advento dos **Large Language Models (LLMs)** – modelos de IA generativa como GPT-3/4, ChatGPT, etc. – trouxe um novo paradigma de interação homem-computador. Em vez de interfaces gráficas tradicionais com comandos explícitos, os usuários agora **especificam objetivos em linguagem natural** e recebem respostas geradas pela IA. Nielsen (2023) descreve esse estilo como uma forma inédita de especificação de intenção, **deslocando parte do controle do usuário para o modelo** ¹. Esse deslocamento de controle e o comportamento **autônomo e não determinístico** dos LLMs levantam **novos desafios de UX**. É necessário projetar experiências que ajudem as pessoas a interagir de forma **efetiva e segura** com IA generativa ². A seguir, exploramos achados acadêmicos recentes (2020–2025) sobre princípios de design centrados no usuário para produtos com LLMs, cobrindo desde interfaces (ex.: chatbots) até questões amplas como **confiança, transparência, controle do usuário, feedback, personalização e responsabilidade algorítmica**.

Desafios de UX em Interações com LLMs

Interagir com modelos de IA generativa difere de usar softwares tradicionais e apresenta **desafios únicos de UX**. Estudos ressaltam que interfaces conversacionais abertas (chatbots) com LLMs, embora poderosas, **podem exigir alta alfabetização em IA do usuário** – por exemplo, saber elaborar *prompts* eficientes – o que eleva a barreira de adoção ³. Além disso, a natureza aberta dessas interfaces traz riscos éticos, especialmente em usos de alto impacto: um LLM pode **“alucinar” respostas falsas** com aparente confiança, podendo induzir erros em cenários críticos (como educação ou saúde) ⁴. Também há **preocupações de privacidade**: usuários podem compartilhar dados sensíveis inadvertidamente, já que a conversação dá sensação de informalidade ⁴. Outra limitação observada é que LLMs em formato de chat **têm dificuldades com tarefas complexas de múltiplas etapas**, frequentemente se perdendo ou entrando em contradição ⁵.

Outros desafios de UX reportados na literatura incluem: **inconsistência e imprevisibilidade** das saídas (o mesmo prompt pode gerar resultados distintos), **possíveis vieses e toxicidade** herdados dos dados de treinamento (demandando cuidado para não ofender ou discriminar usuários), e a **tendência dos usuários de antropomorfizar** a IA (atribuindo-lhe mais inteligência ou intenções do que realmente possui). Esses fatores podem **minar a confiança** na ferramenta ou, inversamente, levar a uma confiança exagerada (*overreliance*) nos resultados da IA. Em suma, **produtos com LLMs requerem diretrizes especializadas de design**: estudos recentes destacam que as diretrizes de UX tradicionais para sistemas de IA não cobriam sutilezas específicas da IA generativa ⁶, tornando premente o desenvolvimento de novos princípios focados em **uso seguro, efetivo e ético** dessa tecnologia ⁷.

Modelos e Frameworks de UX para IA Generativa

Para abordar esses desafios, pesquisadores em IHC (Interação Humano-Computador) e designers criaram **frameworks e princípios de design** voltados a UX de sistemas com IA generativa. Um dos avanços notáveis é o conjunto de **Seis Princípios de Design para Aplicações de IA Generativa**, proposto por Weisz et al. (CHI 2024) ⁸. Esses princípios foram desenvolvidos com base em revisão da literatura, feedback de praticantes de design e validação em projetos reais, visando orientar a criação de interfaces **human-centered** para LLMs ⁹ ⁸. Em resumo, os seis princípios são:

- **Design Responsável – Focar em resolver necessidades reais do usuário e prevenir danos.** Adotar uma postura de design centrado no ser humano (e não guiado apenas pelas capacidades da IA); identificar e equilibrar **tensões de valor** entre diferentes stakeholders; e **monitorar ativamente riscos** de uso, incluindo vieses, conteúdo tóxico ou desinformação ¹⁰. Também implica decidir quais comportamentos emergentes do modelo devem ou não ser expostos ao usuário, restringindo funcionalidades que extrapolem o caso de uso pretendido para evitar usos indevidos ¹¹. Em suma, requer incorporar considerações de ética e inclusão desde o início do projeto.
- **Design para Variabilidade Generativa – Ajudar o usuário a gerenciar a multiplicidade de saídas** produzidas pela IA. Isso inclui tirar proveito do fato de modelos gerarem múltiplas respostas possíveis: por exemplo, criar a funcionalidade de gerar **várias sugestões** de saída (mesmo que nem todas sejam mostradas) para aumentar a chance de alguma satisfazer o usuário ¹². Também envolve **visualizar a jornada** do usuário durante a interação – isto é, mostrar o histórico de consultas e respostas para que ele acompanhe as variações geradas – e oferecer meios de **organizar e filtrar** os resultados (curadoria), destacando diferenças importantes entre as alternativas ¹³. Essas estratégias evitam que o usuário se sinta perdido diante de resultados aleatórios e o empoderam a explorar possibilidades de forma controlada.
- **Design para Modelos Mentais – Comunicar claramente ao usuário como a IA funciona e como colaborar com ela**, levando em conta o nível de conhecimento e objetivos do usuário. A interface deve **orientar o usuário quanto à variabilidade** do gerador (deixando claro, por exemplo, que respostas podem divergir a cada tentativa) ¹⁴. Também deve **ensinar o uso eficaz** da ferramenta, seja por meio de explicações embutidas, tutoriais ou exemplos de prompts, ajudando o usuário a compreender as funcionalidades e limitações do sistema ¹⁵. Outro aspecto é entender e **acompanhar o modelo mental do usuário** – o designer deve considerar o que o usuário acredita que a IA pode ou não fazer e alinhar a interface a essas expectativas ¹⁶. Por fim, sempre que possível, **capturar preferências e comportamentos do usuário** para personalizar a interação ¹⁷. Isso pode significar, por exemplo, permitir que o usuário ajuste o estilo das respostas ou forneça feedback que refine o funcionamento, de modo que a IA “aprenda” a se adequar melhor àquele indivíduo.
- **Design para Co-criação – Permitir que o usuário influencie ativamente o processo generativo, trabalhando em colaboração com a IA.** Na prática, isso se traduz em ferramentas para **ajudar o usuário a formular bons prompts** (por exemplo, sugerindo formatos ou fornecendo campos para contexto) ¹⁸. Também envolve oferecer **controles de entrada genéricos**, como parâmetros ajustáveis – quantidade de alternativas geradas, “temperatura”/aleatoriedade, tom de resposta etc. – que dêem ao usuário **controle sobre os outputs** ¹⁹. Idealmente, esses controles devem incluir tanto parâmetros gerais (válidos para qualquer aplicação) quanto específicos do domínio de uso.

Além disso, o sistema deve suportar a **edição colaborativa das saídas**: tanto o usuário quanto a IA podem propor melhorias ou refinamentos no conteúdo gerado ²⁰. Por exemplo, após a IA produzir um texto, o usuário pode editar partes e pedir que a IA reescreva trechos específicos, num ciclo de iteração conjunta. Essa co-criação aumenta a sensação de **agência do usuário**, evitando que ele se sinta submetido a um resultado “imutável” produzido pela máquina.

- **Design para Confiança Apropriada & Dependência – Auxiliar o usuário a calibrar sua confiança na IA**, entendendo quando **pode confiar** e quando **precisa ter cautela** com as respostas do modelo ²¹. Um dos métodos é **ser transparente sobre as capacidades e limitações** da IA, fornecendo explicações claras do que ela pode ou não fazer bem ²². Por exemplo, a interface pode comunicar que “o sistema não tem conhecimento atualizado após data X” ou “esta resposta pode estar incompleta”. Fornecer **justificativas ou fontes para as saídas** também reforça a confiança adequada – exibir as referências usadas para gerar determinada resposta ou o raciocínio resumido do modelo ajuda o usuário a julgar a qualidade da informação ²³. Outra estratégia de design é **introduzir atritos deliberados para evitar excesso de confiança**: por exemplo, pedir confirmações extras ou destacar potenciais erros antes que o usuário tome decisões críticas com base na resposta ²⁴. Isso “desacelera” o fluxo em momentos-chave, incentivando a revisão crítica em vez da aceitação automática. Por fim, é importante **deixar claro o papel da IA no contexto de uso** ²⁵ – se ela é apenas um assistente que sugere conteúdos, ou uma agente autônoma executando ações, etc. Indicadores visuais ou textuais podem lembrar o usuário de que se trata de uma resposta gerada pela máquina, para que ele mantenha discernimento (ex.: marcar conteúdo gerado com um ícone ou cor diferente).

- **Design para a Imperfeição – Preparar o usuário para lidar com respostas possivelmente imperfeitas ou inesperadas**, e oferecer caminhos para contornar isso ²⁶. Um princípio fundamental é **tornar visível a incerteza** inerente ao modelo: a interface pode incluir mensagens de cautela (“o resultado pode não estar correto”) ou indicadores de confiança quando aplicável ²⁷. Também pode **sinalizar lacunas ou dúvidas** identificadas na saída (por exemplo, sublinhando partes que o modelo não tem certeza). Em seguida, deve-se dar ao usuário **meios de avaliar e melhorar as saídas**. Isso envolve tanto **métricas de qualidade** ou critérios que ajudem o usuário a julgar se a resposta atende ao que ele precisa ²⁸, quanto **ferramentas para correção/aperfeiçoamento** – por exemplo, botões de “editar” ou “regenerar” a resposta, opção de pedir esclarecimentos adicionais, ou apresentar alternativas geradas para comparação ²⁹. Por último, é crucial implementar **mecanismos de feedback do usuário**: permitir que o usuário reporte erros, avalie respostas ou forneça comentários, de modo que esses dados possam ser usados para aprimorar continuamente o modelo ou o sistema ³⁰. Essa postura reconhece que o sistema não será perfeito e valoriza a **participação ativa do usuário** na melhoria da experiência.

Esses princípios formam um **framework abrangente de UX** para LLMs, cobrindo desde considerações de alto nível (ética, confiança, papéis do humano e da IA) até estratégias práticas de interface. Vale notar que princípios similares vêm sendo discutidos por empresas e comunidades de design. Por exemplo, o **People + AI Guidebook** (Google PAIR) – lançado em 2019 e atualizado em 2023/24 – traz diretrizes como **“Definir necessidades do usuário”, “Modelos Mentais”, “Explicabilidade e Confiança”, “Feedback + Controle” e “Tratamento de Erros”,** que estão alinhadas com os pontos acima. A diferença é que agora, com a explosão da IA generativa, essas recomendações ganham **novas interpretações e ênfases específicas** para lidar com geração de conteúdo aberto ³¹ ⁸.

Diretrizes de Interface e Interação com LLMs

No nível da interface, um **padrão predominante** em produtos com LLMs é a interface conversacional de **chatbot** ou assistente virtual. Essa abordagem – apresentar um histórico de diálogo onde o usuário insere perguntas e a IA responde – tem a vantagem de ser **natural e flexível**, mas não é a única forma nem sempre a ideal. Pesquisas em contextos específicos mostram benefícios em **combinar o poder dos LLMs com interfaces mais estruturadas**. Por exemplo, no domínio educacional foi proposta a transição de um chatbot genérico para uma aplicação com UI dedicada a feedback: os professores interagiam com a IA por meio de campos e botões específicos (como “gerar feedback baseado em rubrica”), em vez de um chat aberto, reduzindo a necessidade de domínio de *prompting* e diminuindo riscos éticos em tarefas sensíveis ³². Esse estudo apresentou um framework de integração de GenAI de forma pedagógica e ética, ilustrando que **interfaces guiadas por tarefas podem melhorar usabilidade e controle** em comparação com um chat aberto ³³.

Mesmo em interfaces de chat, existem boas práticas emergentes. Uma delas é **oferecer sugestões múltiplas ou autocomplete**. Em vez de retornar apenas uma resposta, o sistema pode gerar diversas e permitir que o usuário escolha a que melhor atende – o que aumenta a chance de satisfação e alivia a carga de ter que refinar manualmente o prompt. Um experimento do CHI 2023 com usuários escrevendo textos assistidos por LLM comparou interfaces que mostravam 1 sugestão vs. 3 sugestões, e que permitiam ou não prompts extras do usuário; o resultado foi que os participantes **preferiam escolher entre múltiplas sugestões prontas do que ter que digitar instruções adicionais para guiar a geração** ³⁴. Escrever *prompts* “não-diegéticos” (ou seja, comandos explícitos separados do texto principal) demandava esforço, então muitos só recorriam a isso quando queriam inspiração sobre um tópico ou fato específico ³⁴. Em suma, **dar opções ao usuário (escolha) pode ser mais efetivo que pedir controle total via instruções**, ao menos para usuários não especializados.

Outra diretriz importante é **manter a interação orientada e contextualizada**. Isso implica a interface **mostrar o histórico** de conversas ou iterações de maneira clara (por exemplo, como blocos de diálogo, ou listando versões anteriores de um texto gerado), ajudando o usuário a **visualizar sua trajetória** e retomando contexto facilmente ¹². Também significa oferecer **dicas visuais ou textuais** dentro da própria interface que eduquem o usuário sobre recursos disponíveis – por exemplo, sugestões de como perguntar algo (“Experimente: ‘resuma o texto acima em três pontos’”) ou indicadores de que o usuário pode editar uma resposta obtida. Essas abordagens guiam o usuário a usar melhor o sistema sem exigir que leia documentação externa, **alinhando-se ao princípio de apoiar modelos mentais efetivos** ¹⁴.

Por fim, **robustez e desempenho** são parte da UX: usuários esperam respostas rápidas e sistema estável. Avaliações de ferramentas generativas via reviews de usuários indicam que problemas como **lentidão de resposta ou falhas recorrentes** geram frustração e afetam seriamente a experiência ³⁵ ³⁶. Assim, do ponto de vista de design de produto, garantir **infraestrutura adequada** (servidores que aguentem a demanda, etc.) faz parte de “desenhar” uma boa UX – a linha entre design e engenharia se estreita quando o assunto é desempenho percebido. Adicionalmente, considerar uma **versão gratuita vs. paga**: muitos usuários reclamam de limitações rígidas em versões grátis (como limites de caracteres ou funcionalidades bloqueadas) ³⁷. Uma recomendação derivada é, dentro do possível, **oferecer alguma funcionalidade essencial mesmo a não-assinantes** para não prejudicar a adoção inicial, e comunicar claramente o que é extra na versão paga, evitando confusão. Em suma, as decisões de **escopo de funcionalidades, tempo de resposta e estabilidade** são partes integrantes do design de UX para LLMs, pois determinam se o usuário conseguirá incorporar a ferramenta em seu fluxo de trabalho diário de forma confiável.

Confiança, Transparência e Calibragem de Reliance

Modelar a confiança do usuário em sistemas de IA é um tópico central de UX para IA. Com LLMs, essa questão ganha contornos novos: o modelo frequentemente apresenta saídas em linguagem natural fluente e confiante, o que pode **dar a ilusão de exatidão** mesmo quando está errado. Projetar para **“confiança apropriada”** significa encontrar um equilíbrio onde o usuário **nem desacredita de tudo (undertrust), nem confia cegamente (overtrust)**, mas sim entende em quais casos a saída da IA é provavelmente útil ou não ²¹. A literatura aponta algumas estratégias de transparência para isso:

- **Explicitar capacidades e limitações:** Interfaces devem **informar o usuário sobre o que a IA sabe ou não sabe**, talvez através de microtextos (“Treinado em dados até 2021; pode não saber eventos recentes”) ou ícones de alerta quando for extrapolar. Por exemplo, diretrizes recomendam **calibrar a confiança usando explicações** – ser claro sobre quão bem o sistema performa diferentes tarefas, para que o usuário ajuste suas expectativas ²². Essa transparência inicial ajuda a **alinhar o modelo mental** do usuário à realidade da IA, evitando tanto expectativas irreais quanto uso excessivamente cauteloso sem necessidade.
- **Justificativas e evidências:** Sempre que possível, fornecer **racionalizações ou fontes** que sustentem a resposta da IA melhora a confiança informada. Um exemplo é citar documentos ou artigos de onde a resposta foi derivada (prática adotada em sistemas como o Bing Chat e outros mecanismos que conectam LLMs à busca), conforme sugerido pelo princípio de dar **racionales for outputs** ²³. Se o modelo sumariza um texto fornecido, a interface pode permitir destacar passagens originárias do sumário. Se o modelo tomou determinados passos em cadeia para chegar à resposta, mostrar um rastro simplificado desse processo (por exemplo, “Pesquisa interna: X; Raciocínio: Y; Conclusão: Z”) pode ajudar usuários avançados a validar o resultado. Estudos de transparência (e.g. Liao & Vaughan 2023) ressaltam, porém, que a **forma da explicação importa** – ela deve ser compreensível e útil para o usuário, não sobrecarregá-lo. Em LLMs, ainda exploramos a melhor maneira de explicar respostas probabilísticas e complexas de modo amigável.
- **Indicação de incerteza e erros potenciais:** Complementando as justificativas, **assinalar incertezas conhecidas** do modelo aumenta a transparência. O design pode incorporar frases como “Desculpe, não tenho certeza disso” quando apropriado, ou sinalizadores quando o modelo “chutou” informações. Um trabalho recente investigou se LLMs podem comunicar seu próprio nível de incerteza de forma útil ao usuário, de modo a reduzir confiança indevida ³⁸. Além disso, **fazer o usuário pausar e revisar** em momentos críticos ajuda: o conceito de **“fricção intencional”** sugere inserir etapas de confirmação ou atraso quando a ação seguinte for de alto risco. Por exemplo, se um assistente jurídico LLM redige automaticamente um contrato, o sistema poderia obrigar uma revisão final do humano destacando cláusulas potencialmente problemáticas antes de finalizar – assim o usuário não assume que está tudo perfeito. Essa abordagem de **“desacelerar para evitar sobreconfiar”** é explicitamente recomendada nas diretrizes de confiança apropriada ²⁴.
- **Identidade da IA e delimitação de responsabilidade:** Por fim, transparência também envolve **deixar claro que é a IA falando e não um humano**, e qual é o escopo de responsabilidade. Interfaces conversacionais devem sinalizar que as respostas são geradas automaticamente (muitas já exibem o nome do bot ou um avatar de IA). Isso se relaciona à **responsabilidade algorítmica**: usuários têm o direito de saber se estão recebendo conteúdo de IA e os limites disso. Cada vez mais, discute-se implementar **disclaimers e políticas de uso** visíveis, informando que “Esta resposta é

gerada por IA e pode conter erros” etc. Embora tais avisos possam passar despercebidos se muito genéricos, eles fazem parte de uma cultura de transparência. Em contextos sensíveis (saúde, finanças), pode-se até integrar **avisos contextuais** – p. ex., se o usuário perguntar “Devo tomar este remédio?”, a IA pode responder com uma ressalva destacada: “⚠ Sou uma IA e não um profissional de saúde. Consulte um médico para orientação personalizada.”. Todas essas medidas visam estabelecer uma **confiança calibrada**: o usuário entende o valor do que a IA oferece, mas continua engajado em avaliar criticamente e a tomar decisões informadas ²¹.

Controle do Usuário e Colaboração Humano-IA

Apesar dos LLMs serem autônomos na geração de conteúdo, **o usuário deve permanecer no comando da interação**. Um bom design de UX garante que o usuário tenha **múltiplas formas de controlar ou influenciar** o comportamento do modelo, evitando a sensação de imprevisibilidade total. Várias das práticas já mencionadas reforçam esse controle: oferecer parâmetros ajustáveis, permitir edição das respostas da IA, fornecer múltiplas opções de saída etc. Esses mecanismos se alinham ao conceito de **co-criação**, onde humano e IA iteram juntos até atingir um resultado satisfatório ^{18 20}.

Uma diretriz essencial é **“ajudar o usuário a se ajudar” na hora de dar instruções à IA**. Nem todo mundo é experiente em *prompt engineering*, então a interface pode incluir auxiliares como: sugestões de como começar a pergunta, preenchimento automático contextual, ou até **templates de prompts para tarefas comuns** (por ex., “Explique em termos simples: ___”). Isso empodera o usuário a orientar a IA sem precisar de conhecimento técnico avançado. De fato, **assistência na formulação de comandos** foi destacada como uma estratégia de *Design para Co-criação*, pois melhora a qualidade do output e reduz frustração do usuário ¹⁸.

Outro aspecto de controle é a **reversibilidade e edição**. O usuário deve sentir que pode corrigir o curso se a IA gerar algo indesejado. Funcionalidades de “desfazer” ou editar a entrada e pedir reprocessamento são muito bem-vindas. Por exemplo, se um assistente de e-mail escreve uma resposta muito formal, o usuário pode ajustar a instrução para “faça mais casual” e o sistema reaplica. Essa **edição iterativa** é comparável a editar um documento em colaboração: o humano vê a IA como parceira que faz sugestões, mas pode aceitá-las ou modificá-las. Estudos de uso revelam que usuários frequentemente alternam entre escrever eles mesmos e usar sugestões da IA conforme a necessidade – ou seja, **combinam controle manual e automático** conforme acham conveniente ³⁹. O design deve apoiar essa alternância sem atrito, por exemplo mantendo o texto editável e não bloqueando intervenções do usuário.

Feedback do usuário é também uma forma de controle a posteriori: através de avaliações (curtidas, estrelas, flags) ou relatando problemas na resposta, o usuário influencia a evolução futura do sistema. Muitos produtos integraram botões de feedback (“Essa resposta foi útil?”) – essa coleta serve tanto para calibrar o modelo (em aprendizados futuros) quanto para **dar voz ao usuário**, aumentando a confiança de que suas correções importam. Weisz et al. sublinham a importância de **mecanismos de feedback integrados na UX** para IA generativa ⁴⁰. Ao clicar “inapropriado” ou “irrelevante”, o usuário sente que não está à mercê da IA, mas pode **apontar erros e melhorar o serviço** (mesmo que indiretamente). No design, é importante mostrar que esse feedback foi recebido – por exemplo, um pequeno texto “Obrigado, usaremos seu feedback para aprimorar o modelo” ou oferecer a opção de explicar o erro – para fechar o ciclo de comunicação.

Em suma, **controle do usuário** em contextos de IA generativa significa permitir intervenção, personalização e correção em todas as etapas da interação. Essa filosofia está alinhada a princípios clássicos de usabilidade (controle e liberdade do usuário, prevenção de erros, reversão de ações) adaptados a um cenário onde a IA toma mais iniciativas do que sistemas tradicionais. O objetivo final é que o usuário sinta a IA como uma **extensão de suas ações** (uma ferramenta maleável) e não como uma caixa-preta autônoma imprevisível.

Feedback, Aprendizado e Personalização

Dar e receber **feedback** é parte fundamental da experiência com LLMs, não só para controle imediato, mas também para **aprendizado mútuo** – do usuário sobre a IA e da IA sobre o usuário. Sob a ótica do usuário, interações sucessivas com o sistema deveriam formar um **ciclo de aprendizagem**: o usuário aprende quais tipos de perguntas produzem boas respostas, e o sistema idealmente **adapta-se aos padrões e preferências do usuário** ao longo do tempo. Essa adaptação cai na esfera da **personalização**, que tem sido apontada como chave para melhorar a satisfação em interações de IA ⁴¹.

Personalização em LLMs pode ocorrer em vários níveis: desde simples ajustes de preferência (por exemplo, o usuário seleciona um tom de voz padrão – formal vs. informal – para as respostas), até sistemas que realmente **aprendem o estilo ou contexto do usuário** conforme interação. Estudos recentes sugerem que adaptar as respostas ao contexto do usuário **aumenta a relevância e a utilidade percebida**, melhorando a experiência em aplicações como suporte ao cliente, educação e saúde ⁴¹. Um exemplo cotidiano é um assistente que saiba, após algumas interações, que o usuário trabalha no ramo X e portanto passe a fornecer respostas mais focadas nesse domínio.

Contudo, a personalização traz desafios de **privacidade e ética**. Para um LLM “aprender” sobre o usuário, ele geralmente precisa armazenar e processar dados pessoais ou históricos de interação, o que requer **transparência e consentimento**. O design deve tornar claro quando e como os dados do usuário são usados para personalizar respostas. Idealmente, deve oferecer **controle sobre esses dados** (opt-out de personalização, apagar histórico, etc.), respeitando princípios de privacidade. Além disso, existe o risco de a personalização acabar **reforçando vieses ou criando filtros** – se a IA se adapta demais às opiniões do usuário, pode deixar de desafiá-lo com informações variadas. Portanto, encontrar um equilíbrio entre **respostas sob medida e manutenção de diversidade e imparcialidade** é importante para a responsabilidade algorítmica ⁴².

Algumas abordagens técnicas de personalização incluem fine-tuning de modelos para preferências individuais ou uso de **Retrieval-Augmented Generation** com um perfil do usuário. Do ponto de vista de UX, entretanto, talvez o mais tangível seja implementar **interfaces para que o usuário forneça preferências explicitamente**. Por exemplo, em um assistente de escrita, perguntar logo no início “Você prefere um estilo mais conciso ou detalhado?” e salvar essa opção. Ou ter um perfil configurável (“áreas de interesse”, “nível de explicações desejado” etc.). Essas interfaces de preferência tornam o processo de personalização **visível e controlável** pelo usuário, em vez de puramente implícito. O princípio **“Ensine o sistema sobre o usuário”** reflete isso – capturar expectativas e preferências de forma transparente para aprimorar as interações ¹⁷.

No contexto de **feedback como aprendizado**, há ainda o aspecto de **aprimoramento contínuo do modelo**. Muitas aplicações enviam os feedbacks dos usuários (curtidas, correções) para equipes de desenvolvimento ou diretamente para pipelines de *reinforcement learning* com feedback humano (RLHF)

para refinar os LLMs. Do ponto de vista do usuário, é valioso comunicar que o sistema está evoluindo: por exemplo, após uma atualização do modelo, avisar “Agora o assistente aprendeu a evitar respostas repetitivas com base no feedback dos usuários”. Isso fecha o ciclo, mostrando que o **feedback teve efeito**, aumentando engajamento e confiança do usuário na plataforma.

Resumindo, **feedback e personalização** andam de mãos dadas para produzir uma UX mais **interativa, adaptativa e centrada no usuário**. O usuário não é apenas um “consumidor” passivo das respostas da IA, mas um **participante ativo** cujo comportamento informa melhorias, e cujas preferências podem moldar a forma como a IA o atende. Esse paradigma de **aprendizado bilateral** (humano aprende a usar IA, IA aprende sobre humano) é uma característica marcante de experiências com IA generativa bem projetadas.

Responsabilidade Algorítmica e Considerações Éticas

Por fim, nenhum debate sobre UX de sistemas de IA estaria completo sem abordar as **implicações éticas e de responsabilidade**. Em produtos movidos a LLMs, designers têm o dever de considerar como as decisões de design **afetam o comportamento da IA e as consequências para os usuários e a sociedade**. O princípio do **Design Responsável** enfatiza exatamente isso: **minimizar danos e garantir alinhamento com valores humanos** deve ser prioridade desde a concepção ¹⁰.

Algumas práticas recomendadas incluem:

- **Identificar e mitigar possíveis danos:** já na fase de design, realizar análises de risco sobre como a IA pode ser mal utilizada ou produzir resultados nocivos. Por exemplo, identificar que um chatbot pode gerar discurso de ódio ou aconselhamento perigoso e então **implementar salvaguardas** (filtros de conteúdo, limites no domínio de resposta) para prevenir esses outputs. Weisz et al. sugerem incorporar mecanismos de **teste e monitoramento contínuo** de danos ao usuário – seja bias, toxicidade ou desinformação – dentro do ciclo de desenvolvimento ⁴³. Isso pode significar testes com públicos diversos, auditorias de respostas ou mesmo componentes automáticos de detecção de toxicidade que avisem quando o modelo ultrapassa certos limites. A UX também pode expor algumas dessas salvaguardas de modo útil, por exemplo: se a IA se recusar a responder algo por questões éticas, explicar ao usuário o porquê (“Desculpe, não posso ajudar com essa solicitação”). Assim, o sistema mantém transparência mesmo ao dizer “não”.
- **Equilibrar valores de diferentes stakeholders:** produtos de IA gerativa muitas vezes envolvem diversos interessados – os usuários finais, as pessoas/empresas donas do conteúdo usado no treinamento, a sociedade em geral (no que tange a impactos como fake news, etc.). Uma abordagem de **design ético** busca **resolver tensões de valor** entre essas partes ⁴⁴. Por exemplo, a **privacidade do usuário** vs. a **melhoria do modelo com dados do usuário**: pode-se optar por algoritmos on-device ou federados que não enviem tudo para servidores, conciliando utilidade e privacidade. Ou a **liberdade de expressão** vs. **segurança**: permitindo geração aberta de conteúdo criativo, mas com moderação para evitar incitação à violência. Essas decisões de trade-off devem ser tomadas explicitamente no design. Frameworks como *Value Sensitive Design* da área de IHC podem ajudar a mapear e endereçar tais questões, garantindo que o produto esteja em linha com valores éticos acordados.
- **Transparência e accountability:** já discutimos transparência com o usuário, mas aqui enfatizamos a **transparência dos desenvolvedores e empresas** sobre o funcionamento e políticas da IA. Boas

práticas incluem publicar **documentação** tipo *model cards* e *user guides* que expliquem limitações conhecidas do modelo, casos de uso recomendados e proibidos, e como reportar problemas. Do ponto de vista de UX, linkar para essa documentação dentro do produto (ex.: um menu “Sobre esta IA”) contribui para uma cultura de abertura. Além disso, estabelecer **procedimentos de responsabilidade** – por exemplo, se o modelo gerar um erro grave, há um canal de suporte para o usuário? Existe revisão humana disponível em segunda instância? Essas camadas de fallback dão segurança ao usuário de que não está sozinho diante de um algoritmo. Em aplicações críticas, uma abordagem “*human-in-the-loop*”, onde decisões finais ficam a cargo de humanos e a IA apenas assiste, pode ser a exigência ética mínima.

- **Inclusão e equidade:** considerar **usuários diversos** no design é parte da responsabilidade. Isso significa testar a UX com pessoas de diferentes **formações, idades, gêneros, culturas e habilidades** para detectar problemas de acessibilidade ou preconceitos embutidos. Por exemplo, um LLM pode ter desempenho pior em entender dialetos ou nomes de certas culturas – a interface poderia mitigar isso dando exemplos diversos ou explicitamente perguntando se a interpretação da IA esteve correta. Incluir ativamente grupos sub-representados no ciclo de design e teste melhora a equidade do produto. Ethical AI research enfatiza a necessidade de **não exacerbar desigualdades** existentes – por exemplo, um assistente de escrita pode beneficiar enormemente pessoas com menos proficiência em certa língua, mas se mal projetado, também pode prejudicar o aprendizado delas (se elas passarem a depender e não praticarem mais). O design responsável requer ponderar esses efeitos de longo prazo.
- **Consentimento e autonomia:** finalmente, respeitar a **autonomia do usuário** é crucial. Isso envolve desde **consentimento para coleta de dados** (como já dito), até respeitar escolhas do usuário dentro da interação. Se ele diz a um chatbot “não quero mais sugestões sobre este assunto”, o sistema deve acatar. Um exemplo prático: assistentes de código baseados em LLM geralmente têm um botão para desligar/ligar as sugestões autocompletadas, para que o programador tenha paz se quiser escrever sozinho. Essa possibilidade de *opt-out* de recursos de IA dentro do produto é saudável para dar senso de controle e evitar *over-reliance*. Em resumo, ser *user-centric* em IA significa também **dar ao usuário autonomia sobre quanta IA ele quer envolvida** em sua experiência.

Em todos esses pontos, nota-se que **UX para LLMs está intimamente ligada à noção de responsabilidade social e ética**. Um design descuidado pode levar a consequências negativas – desde usuários desorientados ou assustados, até desinformação em larga escala propagada por ferramentas populares. Por outro lado, um design bem pensado pode **mitigar riscos e potencializar benefícios**, promovendo confiança, segurança e utilidade. Como afirmam Liao & Vaughan (2024), a transparência e demais princípios de IA responsável devem ser encarados como um “**roadmap**” de **pesquisa centrada no humano** na era dos LLMs, integrando lições de IHC para enfrentar os dilemas atuais da IA ⁴⁵. Em suma, **projetar a experiência do usuário para IA generativa** não é apenas uma questão de ergonomia ou usabilidade, mas também de **garantir que essa poderosa tecnologia sirva aos usuários de forma compreensível, controlável e confiável****, respeitando seus valores.

Conclusão

Entre 2020 e 2025, a pesquisa acadêmica e prática de design convergiram para começar a responder como criar UX eficaz e responsável para produtos com LLMs. Vimos emergir **princípios de design dedicados** – abordando confiança, transparência, controles, colaboração, personalização e ética – que complementam e

reinterpretam diretrizes clássicas de IHC na nova realidade da IA generativa ⁸ ⁴⁶ . Apesar dos avanços, este campo ainda está evoluindo rapidamente. Novos desafios continuam surgindo (por exemplo, LLMs multimodais que geram não só texto mas imagens e áudio, o que adiciona camadas à UX; ou questões de **vício e dependência** de chatbots cada vez mais verossímeis). A **literatura recente** reforça que a chave é manter o foco no **humano no centro da interação** – projetar sistemas que amplifiquem habilidades humanas e não substituam julgamento humano, fornecendo **transparência, opções e salvaguardas** adequadas ¹⁰ ⁴⁷ .

Em resumo, projetar UX para produtos com LLMs exige uma abordagem multidisciplinar, unindo conhecimentos de interação humano-computador, aprendizado de máquina e ética. As **melhores práticas emergentes** incluem: comunicar claramente o que a IA faz, dar controle e voz ao usuário, apoiar o usuário em entender e ajustar o comportamento da IA, e responsabilizar-se pelos impactos do sistema. Seguir esses princípios e diretrizes – fundamentados em estudos recentes de conferências como CHI, IUI, NeurIPS e outros – aumentará as chances de criar experiências com IA generativa que sejam **úteis, utilizáveis e dignas de confiança** para todos os usuários.

Referências Bibliográficas: As referências a pesquisas e diretrizes apresentadas foram retiradas de estudos acadêmicos e técnicos publicados entre 2020 e 2024, incluindo artigos do CHI Conference on Human Factors in Computing Systems, Harvard Data Science Review, arXiv e outros, conforme citados ao longo do texto. ⁴⁸ ³ ¹⁰ ³⁴ ⁴¹ essas citações ilustram alguns dos pontos-chave discutidos. Em particular, destacam-se: Weisz et al. (2024) com seis princípios de design para UX com IA generativa ⁴⁷ ²⁶ ; diretrizes do Google PAIR atualizadas para IA generativa (Jana & Pushkarna, 2023) focando em transparência, feedback e segurança; estudos de confiança em IA que propõem calibragem da confiança do usuário com explicações e contenção de *overreliance* ²¹ ; e trabalhos sobre co-criação homem-IA mostrando a preferência dos usuários por interfaces que oferecem sugestões selecionáveis em vez de requerer controle manual absoluto ³⁴ . Todos esses contribuíram para as recomendações consolidadas aqui, no esforço de guiar o design de experiências valiosas e responsáveis com LLMs.

1 2 6 8 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 40 43 44 46

47 48 [2401.14484] Design Principles for Generative AI Applications

<https://ar5iv.labs.arxiv.org/html/2401.14484v1>

3 4 5 32 33 [2404.11072] Large Language Models Meet User Interfaces: The Case of Provisioning Feedback

<https://ar5iv.org/html/2404.11072v1>

7 35 36 37 User-centric AI: evaluating the usability of generative AI applications through user reviews on app stores - PMC

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11623163/>

9 [2401.14484] Design Principles for Generative AI Applications

<https://arxiv.org/abs/2401.14484>

34 39 [2303.03199] Choice Over Control: How Users Write with Large Language Models using Diegetic and Non-Diegetic Prompting

<https://arxiv.org/abs/2303.03199>

38 Establishing Appropriate Trust in AI through Transparency and ...

<https://dl.acm.org/doi/10.1145/3613905.3638184>

41 42 Personalization of Large Language Models: A Survey

<https://arxiv.org/html/2411.00027v2>

45 AI Transparency in the Age of LLMs: A Human-Centered Research ...

<https://hdsr.mitpress.mit.edu/pub/aelql9qy/release/1>